Rapport: Classification du cancer du sein (WDBC) par weighted voting et régression logistique

Reda LAHLOU KASSI

1. Introduction

Ce travail compare deux classifieurs sur le jeu de données Wisconsin Diagnostic Breast Cancer (WDBC) : 569 échantillons, 30 variables numériques issues d'images de noyaux cellulaires, avec 357 cas bénins et 212 cas malins. Le premier est le *weighted voting* de Golub et al. (1999), qui sélectionne les k variables les plus discriminantes et fait voter chacune avec un poids propre. Le second est une régression logistique standardisée utilisant les 30 variables. L'objectif est de comparer leurs performances et d'évaluer la stabilité de la sélection de variables.

2. Données et préparation

Les vérifications automatiques confirment : 569 lignes, 32 colonnes, aucun doublon d'identifiant, aucune valeur manquante, et des effectifs conformes au manifeste (357 bénins, 212 malins). La cible est encodée bénin = 0, malin = 1, et la matrice X contient les 30 variables (colonnes `sample_id` et `diagnosis` exclues).

3. Méthodes

Protocole de validation. Validation croisée stratifiée 5 plis répétée 3 fois (15 plis au total), graine fixée (SEED = 26). Chaque pli est vérifié par des assertions : absence de fuite entre apprentissage et test, et stratification respectée (proportion de malins à ±1 % de la proportion globale).

Weighted voting. Sur chaque jeu d'apprentissage, pour chaque variable j, on calcule le score

$w_j = (\mu_1 - \mu_0) / (\sigma_1 + \sigma_0)$

où μ et σ sont la moyenne et l'écart-type par classe. On retient les k = 10 variables de plus grand |w_j|. La prédiction est le signe de la somme des votes

$V(x) = \Sigma_j w_j \cdot (x_j - m_j)$, avec $m_j = (\mu_0 + \mu_1) / 2$.

Une valeur V ≥ 0 est classée maligne. Toutes les statistiques sont estimées uniquement sur le jeu d'apprentissage.

Régression logistique. Standardisation des 30 variables (moyenne et écart-type estimés sur l'apprentissage seulement, puis appliqués au test), puis régression logistique régularisée L2 (solveur liblinear, C = 1,0).

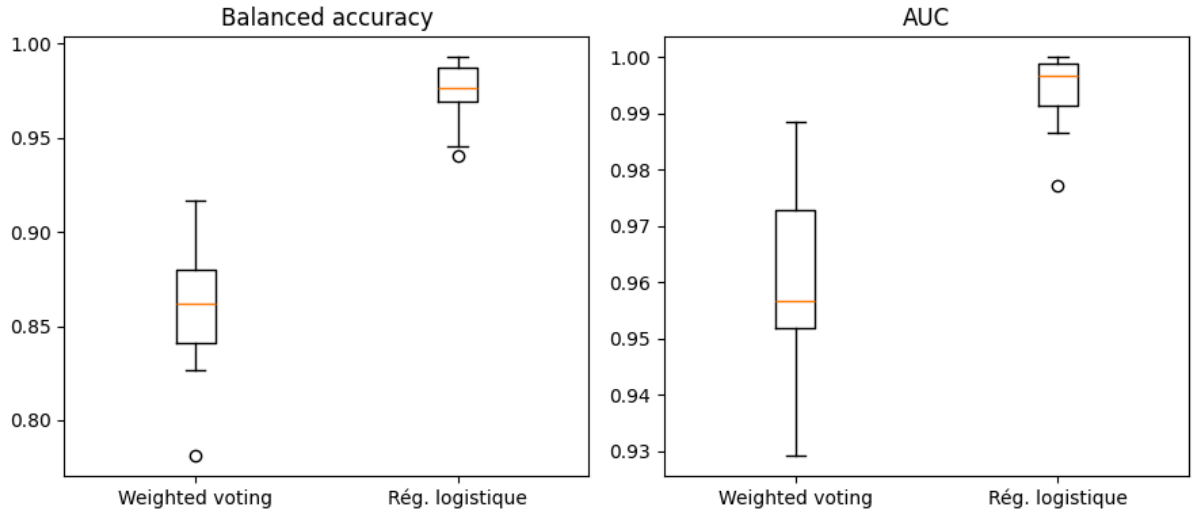
Métriques. Balanced accuracy (adaptée au déséquilibre 63/37) et AUC (calculée sur V(x) pour le weighted voting, sur les probabilités pour la régression logistique). Résultats rapportés en moyenne ± écart-type sur les 15 plis.

4. Résultats

4.1 Performances

Modèle	Balanced Accuracy	AUC
Weighted voting (10 variables)	0,859 ± 0,032	0,961 ± 0,018
Régression logistique (30 variables)	0,975 ± 0,016	0,994 ± 0,007

La régression logistique domine nettement. L'écart est de 11,6 points de balanced accuracy, soit plus de trois écarts-types du weighted voting. Elle est aussi plus régulière d'un pli à l'autre (écarts-types environ deux fois plus faibles).



Le Tableau X et la Figure 2 résument les résultats. La régression logistique obtient une balanced accuracy moyenne de 0,975 (± 0,016) contre 0,859 (± 0,032) pour le weighted voting, et une AUC moyenne de 0,994 (± 0,007) contre 0,961 (± 0,018). Les boîtes à moustaches de la Figure 2 montrent que cet écart n'est pas dû à quelques plis : la régression logistique est meilleure sur l'ensemble de la distribution, avec en plus une dispersion plus faible entre plis.

L'écart est plus marqué pour la balanced accuracy que pour l'AUC. Cela suggère que le weighted voting **classe correctement les patientes** (AUC de 0,96), mais que son **seuil de décision à V(x) = 0** est mal placé pour ces données. La matrice de

confusion du modèle 0 va dans ce sens : 11 tumeurs malignes sur 43 sont classées bénignes, contre un seul faux positif.

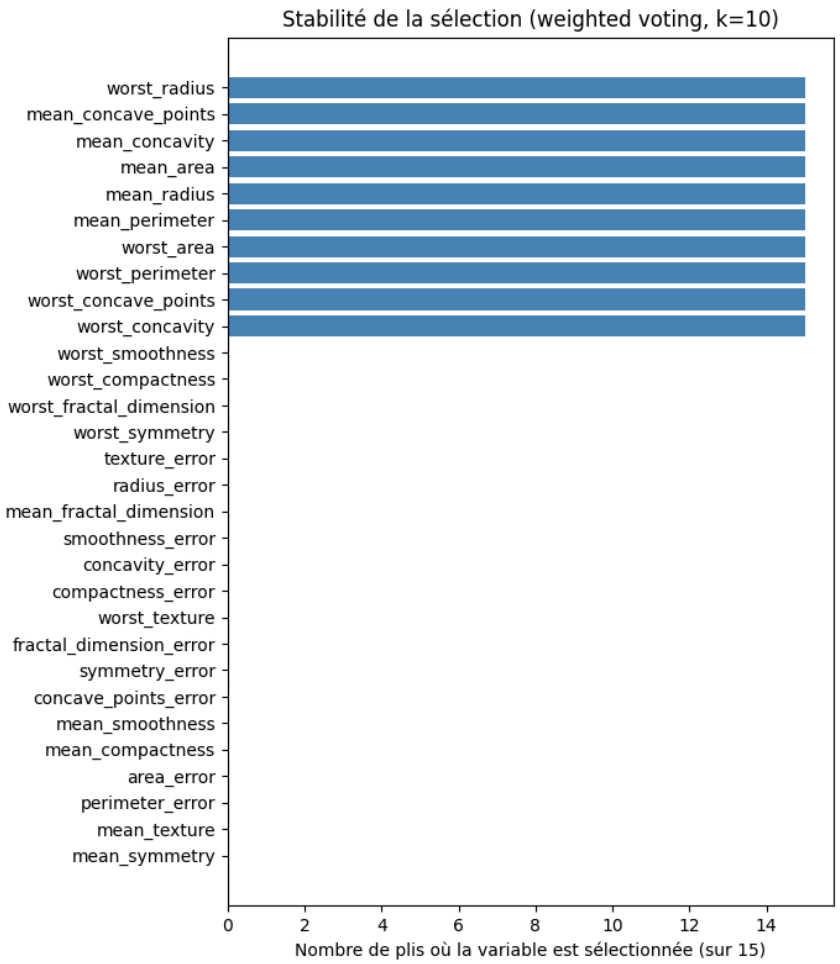
4.2 Stabilité de la sélection de variables

Dix variables sont sélectionnées dans les 15 plis (fréquence 15/15) : mean_radius, mean_perimeter, mean_area, mean_concavity, mean_concave_points et leurs équivalents « worst ». Les 20 autres ne sont jamais retenues (0/15). L'indice de Jaccard moyen entre les ensembles sélectionnés vaut 1,0 : la sélection est parfaitement stable.

5. Discussion

Stabilité et performance sont deux propriétés distinctes. La sélection est identique dans tous les plis, ce qui s'explique par un effectif d'apprentissage élevé (~455 échantillons) devant le nombre de variables (30) : les moyennes et écarts-types estimés fluctuent peu et le classement des |w_j| ne bascule pas. Pourtant, cette sélection parfaitement stable est sous-optimale. Une sélection stable n'est donc pas une preuve de qualité prédictive.

Redondance des variables retenues. Les dix variables sélectionnées décrivent essentiellement la taille du noyau (rayon, périmètre, aire, fortement corrélés) et la concavité. Le vote additif compte plusieurs fois une information quasi identique, sans pouvoir exploiter l'information complémentaire (texture, symétrie, lissage) que la régression logistique combine avec des coefficients ajustés conjointement. Le critère de Golub évalue chaque variable isolément, sans modéliser les corrélations.



Limites. (i) k = 10 est fixé sans optimisation, et un autre k pourrait réduire l'écart. (ii) La stabilité parfaite est propre à ce régime n ≫ p et ne se généralisent pas à des données de type expression génique (p ≫ n). (iii) Une seule cohorte est étudiée, sans validation externe. (iv) Seuls une valeur de C et un seuil de décision par défaut sont utilisés pour la régression logistique, sans réglage interne.

6. Conclusion

Je ne recommanderais pas le weighted voting de Golub pour prédire le diagnostic d'une patiente dans ce contexte. Sa balanced accuracy moyenne (0,859) est nettement inférieure à celle de la régression logistique (0,975), et la Figure 2 montre que cet écart se retrouve sur l'ensemble des plis et pas seulement sur quelques-uns. Dans le modèle, 11 tumeurs malignes sur 43 sont classées bénignes (sensibilité d'environ 74 %), alors qu'un seul cas bénin sur 71 est classé malin (spécificité d'environ 99 %). En pratique clinique, manquer un cancer est bien plus grave que de déclencher un examen complémentaire inutile. Un taux de faux négatifs d'environ un quart est donc inacceptable pour un outil d'aide au diagnostic. Les dix variables retenues sont les mêmes dans les 15 plis (Figure 1, Jaccard moyen de 1), la stabilité

est donc parfaite. Mais cette stabilité est trompeuse : ces variables (rayon, périmètre, aire, concavité, points concaves) sont fortement corrélées entre elles et mesurent en grande partie la même information, la taille du noyau. La méthode, qui note chaque variable indépendamment, sélectionne dix variables largement redondantes et ignore les autres. Une prédiction stable ne signifie donc pas que dix informations indépendantes sont utilisées, et la régression logistique, qui exploite les 30 variables et leurs combinaisons, fait nettement mieux.

7. Reproductibilité

Graine unique (SEED = 26), séparations déterministes, assertions de contrôle sur les données et les plis. Le code et les résultats sont dans `script.ipynb`.